

LINEAMIENTOS DE MODELAMIENTO DE DATOS

Databricks Data Modeling Guidelines

Versión 1.0

Febrero 2026

Tabla de Contenidos

1. Introducción

Este documento establece los lineamientos estándar para el modelamiento de tablas en el entorno Databricks de la organización. Estos estándares buscan garantizar consistencia, escalabilidad y mantenibilidad a largo plazo en todos los desarrollos de datos.

1.1 Objetivos

Los presentes lineamientos tienen como objetivos principales: (a) establecer un lenguaje común y agnóstico para la denominación de objetos de datos, (b) facilitar la comprensión y navegación de modelos de datos por parte de múltiples equipos, (c) garantizar la trazabilidad y auditoría de información, (d) permitir la automatización y estandarización de procesos ETL, y (e) asegurar la escalabilidad del modelo ante futuros requerimientos.

1.2 Alcance

Estos lineamientos aplican a todas las tablas creadas en el entorno Databricks, independientemente de su capa (bronze, silver, gold), periodicidad o tipo de dato. Incluye tablas Delta Lake, vistas materializadas y tablas externas.

2. Convenciones de Nomenclatura para Tablas

2.1 Estructura General

Todas las tablas seguirán la siguiente estructura de nomenclatura:

[PREFIXO_TIPO]_[PERIODICIDAD]_[NOMBRE_DESCRIPTIVO]

Donde cada componente tiene reglas específicas detalladas en las siguientes secciones. Los nombres deben ser completamente en inglés, minúsculas y utilizar guion bajo como separador.

2.2 Prefijos de Tipo de Tabla

El prefijo de tipo identifica la naturaleza funcional de la tabla dentro del modelo de datos.

Prefijo	Tipo	Descripción
h	Historical	Tablas que almacenan histórico completo de datos transaccionales
m	Master	Tablas maestras o de dimensiones que contienen datos de referencia
f	Facts	Tablas de hechos con métricas y medidas agregadas
s	Snapshot	Fotografías puntuales del estado de datos en un momento específico
a	Aggregated	Tablas con datos agregados y consolidados para reportería
t	Temporary	Tablas temporales para procesamiento intermedio (deben eliminarse post-proceso)
c	Calculated	Tablas con campos calculados o métricas derivadas
l	Log	Tablas de auditoría y registro de eventos del sistema

2.3 Indicadores de Periodicidad

El indicador de periodicidad establece la frecuencia con la que se actualiza la información en la tabla.

Código	Periodicidad	Uso
d	Daily	Actualización diaria
w	Weekly	Actualización semanal
m	Monthly	Actualización mensual
h	Hourly	Actualización cada hora
rt	Real-time	Actualización en tiempo real (streaming)
e	Eventually	Actualización eventual o bajo demanda
s	Static	Datos estáticos que no se actualizan

2.4 Ejemplos de Nomenclatura de Tablas

Nombre de Tabla	Descripción
hd_identity	Histórico diario de identidades de clientes
fm_sales	Hechos mensuales agregados de ventas
ms_customer	Maestro estático de clientes
sw_inventory_snapshot	Snapshot semanal del estado de inventario
ad_revenue_summary	Resumen diario agregado de ingresos
lrt_api_events	Log en tiempo real de eventos de API

3. Convenciones de Nomenclatura para Columnas

3.1 Reglas Generales

Los nombres de columnas deben seguir las siguientes reglas: (a) completamente en minúsculas, (b) en idioma inglés, (c) sin espacios ni caracteres especiales excepto guion bajo, (d) descriptivos y concisos, (e) usar prefijos estándar según el tipo de dato.

3.2 Prefijos Estándar por Tipo de Dato

Prefijo	Tipo de Dato	Ejemplos
cod	Códigos	codcustomer, codproduct, codtransaction
id	Identificadores	iduseruuid, idorder, idsession
flg	Flags / Booleanos	flgactive, flgdeleted, flgpremium
amnt	Montos	amntsales, amnttax, amntdiscount
qty	Cantidades	qtyitems, qtyunits, qtystock
pct	Porcentajes	pctdiscount, pctgrowth, pctcompletion
dt	Fechas	dtcreation, dtupdate, dtexpiration
ts	Timestamps	tsevent, tsprocessed, tsingested
desc	Descripciones	descproduct, descstatus, descerror
nm	Nombres	nmfirst, nmlast, nmfull, nmcompany
txt	Textos largos	txtcomments, txtdescription, txtbody
cnt	Contadores	cntvisits, cntattempts, cntrecords
idx	Índices/Posiciones	idxsequence, idxrank, idxposition
url	URLs	urlwebsite, urlimage, urlapi
json	Datos JSON	jsonmetadata, jsonconfig, jsonpayload

3.3 Columnas Obligatorias de Auditoría

Todas las tablas deben incluir las siguientes columnas de auditoría para garantizar trazabilidad:

Columna	Propósito
tscreated	Timestamp de creación del registro

tsupdated	Timestamp de última actualización
usrcreatedby	Usuario o proceso que creó el registro
usrupdatedby	Usuario o proceso que realizó la última actualización
flgactive	Indicador de si el registro está activo (borrado lógico)

4. Tipos de Datos Estándar

Para garantizar consistencia y optimización de almacenamiento, se establecen los siguientes tipos de datos estándar:

Tipo de Dato	Tipo Databricks	Uso Recomendado
Códigos alfanuméricos	STRING	Códigos de cliente, producto, transacción
Identificadores únicos	STRING (UUID)	IDs generados por sistema, correlación
Enteros pequeños	INT	Cantidades, contadores, índices
Enteros grandes	BIGINT	Timestamps en epoch, IDs numéricos
Montos monetarios	DECIMAL(18,2)	Precios, montos de ventas, impuestos
Porcentajes	DECIMAL(5,4)	Tasas, descuentos (almacenar como 0.1525 = 15.25%)
Booleanos	BOOLEAN	Flags, indicadores (true/false)
Fechas	DATE	Fechas sin componente de tiempo
Fecha y hora	TIMESTAMP	Eventos con fecha y hora exacta, auditoría
Datos estructurados	STRUCT	Objetos anidados con esquema conocido
Arrays	ARRAY<TYPE>	Listas de elementos del mismo tipo
Mapas clave-valor	MAP<K,V>	Pares clave-valor dinámicos

5. Estrategias de Particionamiento

5.1 Criterios de Particionamiento

El particionamiento debe basarse en los patrones de consulta más frecuentes y debe considerar: (a) volumen de datos por partición (objetivo 500MB a 1GB), (b) cardinalidad de la columna de partición, (c) frecuencia de consultas por partición, (d) crecimiento histórico de datos.

5.2 Columnas de Partición Estándar

Columna	Uso Recomendado
dtpartition	Partición por fecha (YYYY-MM-DD) para datos históricos diarios
yearpartition	Partición por año (YYYY) para datos históricos de largo plazo
monthpartition	Partición por mes (YYYY-MM) para agregaciones mensuales
regionpartition	Partición por región geográfica cuando las consultas son por región

6. Buenas Prácticas y Estándares de Calidad

6.1 Documentación de Tablas

Todas las tablas deben incluir: (a) descripción clara del propósito en propiedades de tabla (COMMENT), (b) descripción de cada columna, (c) definición de claves primarias y foráneas cuando aplique, (d) información sobre el proceso de carga (frecuencia, fuente), (e) responsable o equipo propietario de la tabla.

6.2 Optimización de Almacenamiento

Para optimizar el almacenamiento: (a) utilizar OPTIMIZE regularmente en tablas Delta, (b) configurar Z-ORDER en columnas de alta cardinalidad frecuentemente filtradas, (c) ejecutar VACUUM para eliminar archivos obsoletos (considerando retention period), (d) revisar tamaño de archivos con DESCRIBE DETAIL.

6.3 Control de Calidad de Datos

Implementar validaciones en cada capa: (a) validación de NOT NULL en campos críticos, (b) validación de rangos y formatos, (c) checks de duplicados en claves primarias, (d) reconciliación de conteos entre capas, (e) alertas automáticas en caso de anomalías.

6.4 Versionamiento y Esquemas

Para evolución de esquemas: (a) utilizar merge schema solo cuando sea necesario, (b) documentar todos los cambios de esquema, (c) considerar compatibilidad hacia atrás, (d) versionar esquemas críticos, (e) comunicar cambios al equipo.

6.5 Seguridad y Gobernanza

Aplicar políticas de seguridad: (a) uso de Unity Catalog para control de acceso, (b) enmascaramiento de datos sensibles (PII), (c) registro de accesos mediante audit logs, (d) clasificación de datos según nivel de sensibilidad, (e) cumplimiento con regulaciones (GDPR, CCPA).

7. Casos de Uso y Ejemplos Completos

7.1 Ejemplo: Tabla de Transacciones Históricas

Tabla: `hd_sales_transactions`

Esta tabla almacena el histórico completo de transacciones de ventas con actualización diaria.

Columna	Tipo	Descripción
<code>idtransaction</code>	STRING	ID único de transacción (UUID)
<code>codcustomer</code>	STRING	Código de cliente
<code>codproduct</code>	STRING	Código de producto
<code>amntsales</code>	DECIMAL(18,2)	Monto total de venta
<code>qtyitems</code>	INT	Cantidad de items
<code>dttransaction</code>	TIMESTAMP	Fecha y hora de transacción
<code>dtpartition</code>	DATE	Partición por fecha
<code>tscreated</code>	TIMESTAMP	Timestamp de creación

7.2 Ejemplo: Tabla Maestra de Productos

Tabla: `ms_product`

Tabla maestra estática que contiene el catálogo de productos.

Columna	Tipo	Descripción
<code>codproduct</code>	STRING	Código único de producto (PK)
<code>nmproduct</code>	STRING	Nombre del producto
<code>descproduct</code>	STRING	Descripción del producto
<code>codcategory</code>	STRING	Código de categoría
<code>amntprice</code>	DECIMAL(18,2)	Precio unitario
<code>flgactive</code>	BOOLEAN	Producto activo/inactivo
<code>tscreated</code>	TIMESTAMP	Timestamp de creación
<code>tsupdated</code>	TIMESTAMP	Timestamp de actualización

8. Anexos

8.1 Glosario de Términos

Delta Lake: Capa de almacenamiento open-source que proporciona transacciones ACID sobre data lakes.

Z-ORDER: Técnica de optimización que co-localiza datos relacionados en el mismo conjunto de archivos.

Unity Catalog: Solución de gobernanza unificada para gestión de datos y AI en Databricks.

Medallion Architecture: Patrón de diseño de datos con capas Bronze (raw), Silver (refined) y Gold (aggregated).

8.2 Referencias

- Databricks Delta Lake Documentation
- Best Practices for Data Engineering on Databricks
- Unity Catalog Governance Guide

8.3 Control de Versiones

Versión	Fecha	Autor	Cambios
1.0	Febrero 2026	Equipo de Datos	Versión inicial del documento

Fin del Documento